

TRƯỜNG ĐẠI HỌC
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỀ TÀI

HỆ THỐNG PHÂN TÍCH VÀ DỰ ĐOÁN GIÁ TIỀN MÃ HÓA THEO THỜI GIAN THỰC DỰA TRÊN KIẾN TRÚC LAMBDA

Môn học: CS315 – Advanced Machine Learning

Sinh viên thực hiện: Họ và tên – MSSV

Giảng viên hướng dẫn:

Nhóm: CN2

Mục lục

1	GIỚI THIỆU ĐỀ TÀI	6
1.1	Tính cấp thiết của đề tài	6
1.2	Mô tả bài toán	6
1.3	Đối tượng và phạm vi nghiên cứu	6
1.4	Mục tiêu đề tài	6
2	NGHIÊN CỨU LIÊN QUAN	7
2.1	Dự đoán giá tiền mã hóa bằng học sâu	7
2.2	Xử lý dữ liệu tài chính theo thời gian thực	7
2.3	Kiến trúc Lambda trong phân tích dữ liệu lớn	7
2.4	Chỉ số kỹ thuật và phân tích tài chính	7
2.5	Điểm mới của đề tài	8
3	BỘ DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ	9
3.1	Thu thập dữ liệu	9
3.1.1	Nguồn dữ liệu và phương thức thu thập	9
3.1.2	Cấu trúc dữ liệu thô	9
3.1.3	Thống kê mô tả dữ liệu thô	9
3.2	Phân tích khám phá dữ liệu	10
3.2.1	Biến động giá theo thời gian	10
3.2.2	Phân phối log-return — lý do không dùng MSE	11
3.2.3	Kiểm định tính dừng (Stationarity)	12
3.2.4	Phân tích khối lượng giao dịch	13
3.2.5	Rolling statistics và xu hướng	13
3.3	Tương quan Bitcoin – Dogecoin	14
3.4	Xây dựng đặc trưng (Feature Engineering)	14
3.4.1	Thiết kế bộ đặc trưng 9 chiều	14
3.4.2	Phân tích đặc trưng trực quan	16
3.4.3	Warmup và số hàng hợp lệ	17
3.5	Phân chia tập dữ liệu	17
3.5.1	Nguyên tắc phân chia chronological	17
3.5.2	Rolling window và cơ chế phân chia	18
3.5.3	Phân phối nhãn hướng (direction labels)	18
3.6	Tóm tắt chương	19

4	PHƯƠNG PHÁP ĐỀ XUẤT	20
4.1	Tổng quan kiến trúc Lambda	20
4.2	Speed Layer: Kafka và Spark Streaming	20
4.2.1	Kafka Producer	20
4.2.2	Spark Structured Streaming	20
4.3	Batch Layer: Spark Batch Job	21
4.4	Mô hình LSTM Dual-Head (v3)	21
4.4.1	Kiến trúc tổng thể	21
4.4.2	LSTM Encoder	22
4.4.3	Price Head và Volatility Head	23
4.4.4	Hàm mất mát (Loss Function)	23
4.4.5	Quy trình huấn luyện	23
4.5	Walk-Forward Validation	24
5	THỰC NGHIỆM VÀ KẾT QUẢ	25
5.1	Môi trường thực nghiệm	25
5.2	Quy trình thực nghiệm	25
5.3	Độ đo đánh giá	25
5.4	Kết quả trên tập kiểm thử	26
5.4.1	So sánh BTC và DOGE	26
5.4.2	Phân tích MAE theo từng bước dự đoán	27
5.4.3	Dự đoán vs. Giá thực tế	27
5.4.4	Trực quan hóa dự đoán 7 ngày	28
5.4.5	Phân tích Volatility Head	29
5.5	Walk-Forward Validation	29
5.5.1	Kết quả tổng hợp	29
5.5.2	Kết quả theo từng fold (Bitcoin)	30
5.6	Backtest 6 Tháng (Bitcoin)	30
5.6.1	Phương pháp	30
5.6.2	Kết quả so sánh đa horizon	31
6	KẾT LUẬN	32
6.1	Tóm tắt đóng góp	32
6.2	Hạn chế và điểm cần cải thiện	32
6.3	Kết luận	33
7	HƯỚNG PHÁT TRIỂN	34

Danh sách hình vẽ

3.1	Lịch sử giá đóng cửa hàng ngày: Bitcoin (log scale, trên) và Dogecoin (tuyến tính, dưới). Trục tung BTC dùng log scale do biên độ dao động quá lớn (\$172 đến \$124.753).	10
3.2	Drawdown analysis: mức sụt giảm so với đỉnh lịch sử. DOGE có các đợt sụt giảm sâu hơn và kéo dài hơn BTC, phản ánh tính đầu cơ cao hơn.	11
3.3	Phân phối log-return hàng ngày của BTC (trái) và DOGE (phải). Đường nét đứt là phân phối chuẩn cùng mean/std. Cả hai đều có <i>fat tails</i> rõ ràng.	11
3.4	Khối lượng giao dịch hàng ngày của BTC (trên) và DOGE (dưới). Đỉnh DOGE năm 2021 vượt cả BTC trong giai đoạn ngắn, phản ánh cơn sốt đầu cơ.	13
3.5	Giá đóng cửa (mở) cùng trung bình trượt 30 ngày ± 1 độ lệch chuẩn. Dải $\pm 1\sigma$ giãn nở mạnh trong các giai đoạn biến động cao.	13
3.6	Trên: tương quan Pearson trượt 30 ngày và 90 ngày giữa log-return BTC và DOGE. Dưới: scatter plot log-return hàng ngày với đường hồi quy OLS.	14
3.7	Chuỗi thời gian của 9 đặc trưng cho Bitcoin (sau khi loại bỏ 29 hàng warmup). RSI_14 thêm đường ngưỡng 30 và 70; bb_pct_b thêm ranh giới dải Bollinger.	16
3.8	Ma trận tương quan Pearson giữa 9 đặc trưng (Bitcoin). Giá trị dương = màu đỏ, âm = màu xanh. Tương quan cao nhất giữa <code>atr_norm</code> và <code>realized_vol_14d</code> ($r \approx 0,7$) là chấp nhận được vì cả hai đo biến động, nhưng ở thang thời gian khác nhau (tức thì vs. 14 ngày).	17
3.9	Phân bố số lượng chuỗi input trong ba tập dữ liệu (cửa sổ training 730 ngày). Tập validation và test mỗi tập tương ứng khoảng 73 ngày liên tiếp cuối cùng của cửa sổ.	18
3.10	Phân phối target log-return tại bước 1, 3, 7 ngày (Bitcoin). Phương sai tăng dần theo horizon, cho thấy bài toán dự đoán bước 7 khó hơn đáng kể.	18
4.1	So sánh số lượng tham số giữa các thành phần của mô hình. LSTM encoder chiếm hơn 90% tổng tham số; các auxiliary heads nhẹ để tránh overfitting.	22
5.1	So sánh hiệu suất mô hình BTC và DOGE theo các độ đo. BTC có RMSE tuyệt đối lớn hơn nhiều (theo USD) nhưng MAPE thấp hơn DOGE do giá BTC cao hơn.	26
5.2	MAE theo từng bước dự đoán (step 1–7) cho BTC và DOGE. MAE tăng dần theo horizon — step 7 khó hơn step 1 đáng kể, đặc biệt với DOGE do biến động cao.	27

- 5.3 Scatter plot giá dự đoán vs. giá thực tế (USD) trên tập test, tất cả 7 bước. Đường nét đứt là đường lý tưởng $\hat{p} = p$. Điểm gần đường này hơn = dự đoán chính xác hơn. 27
- 5.4 Phân tích phần dư (residuals) của mô hình BTC: phân phối residuals (trái) và residuals theo thứ tự thời gian (phải). Không có autocorrelation rõ ràng — tốt cho mô hình hồi quy. 28
- 5.5 Ví dụ dự đoán 7 ngày cho BTC (đường xanh dương) so với giá thực tế (đường cam). Vùng tô màu biểu diễn khoảng tin cậy ± 1 vol từ volatility head. . . . 28
- 5.6 So sánh volatility được dự đoán bởi volatility head (nét xanh) với realized volatility thực tế (nét cam). Mô hình học được pattern “volatility clustering” — giai đoạn biến động cao nối tiếp nhau. 29
- 5.7 Directional accuracy theo từng fold walk-forward cho BTC và DOGE. Dao động giữa các fold (38%–56%) phản ánh sự thay đổi regime của thị trường crypto qua các giai đoạn khác nhau. 30

Danh sách bảng

3.1	Thống kê mô tả dữ liệu thô — Bitcoin và Dogecoin	10
3.2	Thống kê log-return hàng ngày	12
3.3	Kết quả kiểm định ADF ở mức ý nghĩa $\alpha = 0,05$	12
3.4	Bộ 9 đặc trưng đầu vào — định nghĩa, giá trị thực tế (BTC) và lý do chọn	15
4.1	Các chỉ số kỹ thuật tính toán trong Spark Streaming	21
4.2	Thông số kiến trúc mô hình LSTM v3	22
4.3	Siêu tham số huấn luyện	23
5.1	Các services trong Docker Compose	25
5.2	Kết quả trên tập test (10% cuối của rolling window 730 ngày, 73 ngày)	26
5.3	Kết quả walk-forward validation (6 fold $\times$ 60 ngày/fold)	29
5.4	Chi tiết từng fold walk-forward — Bitcoin (horizon = 7 ngày)	30
5.5	Kết quả backtest BTC theo horizon (6 tháng: 01/2026–05/2026)	31

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1. Tính cấp thiết của đề tài

Thị trường tiền mã hóa (cryptocurrency) phát triển với tốc độ nhanh chóng và có mức độ biến động cao. Việc dự đoán xu hướng giá trong ngắn hạn mang lại giá trị lớn cho nhà đầu tư và các tổ chức tài chính. Tuy nhiên, phần lớn các hệ thống hiện tại chỉ xử lý dữ liệu theo lô (batch), không đáp ứng được nhu cầu phân tích gần thời gian thực.

Đề tài này đề xuất xây dựng một pipeline dữ liệu hoàn chỉnh theo kiến trúc Lambda, kết hợp xử lý batch và streaming để cung cấp thông tin phân tích kịp thời, đồng thời ứng dụng mô hình học sâu LSTM để dự đoán giá 7 ngày tiếp theo.

1.2. Mô tả bài toán

Input: Dữ liệu giá theo thời gian thực của Bitcoin (BTC) và Dogecoin (DOGE) từ CoinGecko API, bao gồm: giá đóng/mở/cao/thấp, khối lượng giao dịch, market cap.

Output:

- Các chỉ số kỹ thuật (SMA, RSI, Bollinger Bands, VWAP, ATR) được tính toán theo thời gian thực.
- Dự đoán giá 7 ngày tiếp theo kèm hướng xu hướng (tăng/giảm).
- Dashboard trực quan hóa toàn bộ pipeline.

1.3. Đối tượng và phạm vi nghiên cứu

Đối tượng: Bitcoin (BTC) và Dogecoin (DOGE) – hai đồng tiền mã hóa có khối lượng giao dịch lớn và tính đại diện cao.

Phạm vi:

- Dữ liệu lịch sử từ CoinGecko (tối thiểu 2 năm).
- Dự đoán giá ngắn hạn (7 ngày).
- Hệ thống chạy cục bộ với Docker Compose (9 services).

1.4. Mục tiêu đề tài

1. Xây dựng pipeline dữ liệu Lambda Architecture hoàn chỉnh.
2. Tính toán các chỉ số kỹ thuật theo thời gian thực bằng Spark Streaming.
3. Huấn luyện mô hình LSTM dual-head dự đoán giá và xu hướng.
4. Xây dựng API (FastAPI) và giao diện người dùng (React + Streamlit).

CHƯƠNG 2. NGHIÊN CỨU LIÊN QUAN

2.1. Dự đoán giá tiền mã hóa bằng học sâu

Nhiều nghiên cứu đã ứng dụng mạng LSTM để dự đoán giá Bitcoin [1]. LSTM có khả năng học các phụ thuộc dài hạn trong chuỗi thời gian, phù hợp với bản chất tuần tự của dữ liệu tài chính. Fischer và Krauss [1] chứng minh rằng LSTM vượt trội so với các mô hình thống kê truyền thống (ARIMA, Random Forest) trên dữ liệu S&P 500 nhờ khả năng nắm bắt phi tuyến tính trong chuỗi tài chính. Các biến thể như Bi-LSTM, LSTM kết hợp Attention cũng được đề xuất để cải thiện độ chính xác dự đoán [2].

Mô hình LSTM gốc được giới thiệu bởi Hochreiter và Schmidhuber [3], giải quyết vấn đề vanishing gradient trong RNN thông thường thông qua cơ chế cổng (gate mechanism). Đơn vị LSTM gồm ba cổng: cổng đầu vào (input gate), cổng quên (forget gate) và cổng đầu ra (output gate), điều phối luồng thông tin qua cell state.

2.2. Xử lý dữ liệu tài chính theo thời gian thực

Apache Kafka và Apache Spark Structured Streaming là bộ đôi phổ biến trong các hệ thống phân tích tài chính thời gian thực [4]. Spark hỗ trợ tính toán cửa sổ trượt (sliding window), watermark cho dữ liệu trễ, và tích hợp dễ dàng với MongoDB thông qua foreachBatch pattern. Zaharia et al. [4] mô tả Spark như một unified engine xử lý cả batch và streaming trên cùng một API, giảm thiểu độ phức tạp vận hành so với việc duy trì hai hệ thống riêng biệt.

2.3. Kiến trúc Lambda trong phân tích dữ liệu lớn

Kiến trúc Lambda [5] do Nathan Marz đề xuất phân tách rõ ràng giữa batch layer (độ chính xác cao, độ trễ cao) và speed layer (độ trễ thấp, xấp xỉ), phục vụ cả hai nhu cầu thông qua serving layer. Kiến trúc này đặc biệt phù hợp cho các hệ thống tài chính cần cả phân tích lịch sử chính xác (báo cáo, đào tạo mô hình) và phản ứng nhanh với dữ liệu mới (cảnh báo, dashboard realtime).

2.4. Chỉ số kỹ thuật và phân tích tài chính

Murphy [6] hệ thống hóa toàn bộ phân tích kỹ thuật tài chính, bao gồm các chỉ số SMA, RSI, Bollinger Bands, và VWAP. Các chỉ số này được sử dụng rộng rãi trong thực tế giao dịch và đã được chứng minh mang lại giá trị dự báo bổ sung khi kết hợp với mô hình học máy. Để tận dụng các chỉ số này như các feature đầu vào cho LSTM thay vì dùng raw price.

2.5. Điểm mới của đề tài

- Kết hợp Lambda Architecture với mô hình LSTM v3 (volatility head bổ sung).
- Áp dụng direction-weighted Huber loss để buộc mô hình ưu tiên dự đoán đúng hướng xu hướng.
- Tích hợp walk-forward validation (6 fold) và backtest 6 tháng để đánh giá mô hình thực tế.
- Hệ thống end-to-end hoàn chỉnh với Docker Compose, bao gồm cả frontend React và model registry.

CHƯƠNG 3. BỘ DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ

Chương này mô tả toàn bộ quá trình thu thập, xử lý và phân tích dữ liệu, từ nguồn API thô đến bộ đặc trưng đầu vào cuối cùng cho mô hình LSTM. Mỗi quyết định kỹ thuật đều được trình bày kèm theo lý do xuất phát từ đặc điểm thực tế của dữ liệu tài chính.

3.1. Thu thập dữ liệu

3.1.1. Nguồn dữ liệu và phương thức thu thập

Toàn bộ dữ liệu giá được lấy từ **CoinGecko API** [7] — nền tảng dữ liệu thị trường tiền mã hóa với lịch sử hơn 10 năm. Hệ thống sử dụng hai kênh song song:

- **Dữ liệu lịch sử (offline):** Tải xuống CSV cho toàn bộ lịch sử giá hàng ngày (`data/sample/bitcoindogecoin.csv`), phục vụ huấn luyện mô hình LSTM.
- **Dữ liệu streaming (online):** Kafka producer polling CoinGecko mỗi 600 giây, đẩy JSON vào topic `crypto_raw`, phục vụ speed layer và dashboard realtime.

Sự tách biệt này xuất phát từ ràng buộc thực tế: CoinGecko demo tier giới hạn 10.000 lượt gọi API mỗi tháng. Nếu dùng streaming để thu thập dữ liệu huấn luyện, hệ thống sẽ cạn hạn mức trong vài ngày. Cách tiếp cận hybrid — CSV cho training, streaming cho serving — giải quyết mâu thuẫn này mà không đánh đổi tính thời gian thực.

3.1.2. Cấu trúc dữ liệu thô

Mỗi bản ghi trong CSV và Kafka message có schema thống nhất gồm 5 trường:

```
{date, close, total_volume, market_cap, coin_name}
```

Dữ liệu được thu thập cho **Bitcoin (BTC)** và **Dogecoin (DOGE)** — hai đồng coin được chọn vì khối lượng giao dịch lớn, lịch sử dài, và tính đại diện khác nhau (BTC là store-of-value, DOGE có tính đầu cơ/meme cao hơn).

3.1.3. Thống kê mô tả dữ liệu thô

Bộ dữ liệu sau khi tải về gồm 4.165 quan sát mỗi coin, trải dài từ **01/01/2015 đến 29/05/2026** (11,4 năm).


Bảng 3.1: Thống kê mô tả dữ liệu thô — Bitcoin và Dogecoin

Coin	Thuộc tính	Min	Max	Mean	Std
Bitcoin	Giá đóng cửa (USD)	172,15	124.752,53	29.277,59	32.519,39
	Khối lượng GD (USD)	0	181,7 tỷ	22,6 tỷ	22,7 tỷ
	Market cap (USD)	0	1,44 nghìn tỷ	243,6 tỷ	319,3 tỷ
Dogecoin	Giá đóng cửa (USD)	0,0001	0,6818	0,0706	0,0963
	Khối lượng GD (USD)	0	51,0 tỷ	976 triệu	2,71 tỷ
	Market cap (USD)	0	88,8 tỷ	4,85 tỷ	9,78 tỷ

Nhận xét về chất lượng dữ liệu: Mỗi bộ có đúng 1 hàng thiếu `market_cap` (tương đương 0,024%), không ảnh hưởng đến pipeline vì `market_cap` không được dùng làm feature đầu vào. Không có hàng nào thiếu `close` hoặc `total_volume` — hai trường thiết yếu cho mô hình.

3.2. Phân tích khám phá dữ liệu

3.2.1. Biến động giá theo thời gian




Hình 3.1: Lịch sử giá đóng cửa hàng ngày: Bitcoin (log scale, trên) và Dogecoin (tuyến tính, dưới). Trục tung BTC dùng log scale do biên độ dao động quá lớn (\$172 đến \$124.753).

Hình 3.1 cho thấy một số đặc điểm quan trọng:

- **BTC** tăng trưởng bậc thang với các chu kỳ halving rõ ràng (2017, 2020–2021, 2024). Biên độ dao động từ mức đỉnh đến đáy (max drawdown) đạt **–83,64%** trong toàn giai


đoạn.

- **DOGE** có đặc tính hoàn toàn khác: phần lớn thời gian dao động dưới \$0,01, sau đó có các đợt tăng đột biến theo sự kiện bên ngoài (ví dụ: tweet Elon Musk tháng 5/2021 đẩy giá lên \$0,68). Max drawdown đạt **-92,21%** — sâu hơn BTC đáng kể.



Hình 3.2: Drawdown analysis: mức sụt giảm so với đỉnh lịch sử. DOGE có các đợt sụt giảm sâu hơn và kéo dài hơn BTC, phản ánh tính đầu cơ cao hơn.

3.2.2. Phân phối log-return — lý do không dùng MSE



Hình 3.3: Phân phối log-return hàng ngày của BTC (trái) và DOGE (phải). Đường nét đứt là phân phối chuẩn cùng mean/std. Cả hai đều có *fat tails* rõ ràng.

Phân tích phân phối log-return trong Hình 3.3 và Bảng 3.2 là cơ sở quan trọng cho các quyết định thiết kế mô hình:

Bảng 3.2: Thống kê log-return hàng ngày

Coin	Mean	Std	Min	Max	Kurtosis
Bitcoin	+0,001310	0,0353	-0,4337	+0,2871	11,11
Dogecoin	+0,001514	0,0653	-0,5071	+1,4791	77,02

Kurtosis của BTC (= 11,11) và đặc biệt DOGE (= 77,02) lớn hơn nhiều so với phân phối chuẩn (= 3), xác nhận hiện tượng *fat tails* (phân phối leptokurtic). Điều này có nghĩa là các sự kiện cực đoan (crash/pump bất thường) xảy ra thường xuyên hơn nhiều so với lý thuyết thống kê thông thường dự đoán. Đây là lý do chính để chọn **HuberLoss** thay vì **MSE** trong quá trình huấn luyện: HuberLoss kết hợp L_2 cho sai số nhỏ và L_1 cho sai số lớn, giảm thiểu ảnh hưởng của các outlier mà không loại bỏ chúng hoàn toàn.

3.2.3. Kiểm định tính dừng (Stationarity)

Tính dừng là điều kiện tiên quyết để các đặc trưng thống kê ổn định theo thời gian — yêu cầu thiết yếu cho mô hình học sâu. Kiểm định ADF (Augmented Dickey-Fuller) được áp dụng cho chuỗi giá gốc và chuỗi log-return:


Bảng 3.3: Kết quả kiểm định ADF ở mức ý nghĩa $\alpha = 0,05$

Coin	Chuỗi	ADF Statistic	p-value	Kết luận
Bitcoin	Giá đóng cửa	-1,178	0,683	Không dừng
Bitcoin	Log-return 1 ngày	-66,27	≈ 0	Dừng
Dogecoin	Giá đóng cửa	-3,413	0,0105	Dừng (*)
Dogecoin	Log-return 1 ngày	-14,73	≈ 0	Dừng

(*) DOGE có p-value < 0,05 nhưng đây là kết quả dễ bị ảnh hưởng bởi các đợt pump đột biến và không phản ánh tính dừng thực sự của chuỗi giá dài hạn.

Kết quả khẳng định: chuỗi giá BTC **không dừng** (random walk), trong khi log-return của cả hai coin **dừng mạnh** ($p \approx 0$). Đây là lý do feature chính của mô hình là `log_return_1d` thay vì raw close price.


3.2.4. Phân tích khối lượng giao dịch



Hình 3.4: Khối lượng giao dịch hàng ngày của BTC (trên) và DOGE (dưới). Đỉnh DOGE năm 2021 vượt cả BTC trong giai đoạn ngắn, phản ánh cơn sốt đầu cơ.

Khối lượng giao dịch BTC có xu hướng tăng dài hạn và tương quan với các chu kỳ giá. DOGE có các đỉnh khối lượng bất thường (tháng 5/2021 đạt \$51 tỷ — gần bằng đỉnh BTC cùng giai đoạn) phản ánh bản chất đầu cơ ngắn hạn. Đây là lý do log-return của DOGE có kurtosis rất cao (77,02).


3.2.5. Rolling statistics và xu hướng



Hình 3.5: Giá đóng cửa (mờ) cùng trung bình trượt 30 ngày ± 1 độ lệch chuẩn. Dải $\pm 1\sigma$ giãn nở mạnh trong các giai đoạn biến động cao.

Dải $\pm 1\sigma$ (Hình 3.5) cho thấy độ biến động của crypto không đồng nhất theo thời gian (heteroskedastic). Đặc tính này là một phần lý do thêm `realized_vol_14d` vào bộ features — để mô hình có thể “nhìn thấy” trạng thái biến động hiện tại và điều chỉnh dự báo tương ứng.

3.3. Tương quan Bitcoin – Dogecoin



Hình 3.6: Trên: tương quan Pearson trượt 30 ngày và 90 ngày giữa log-return BTC và DOGE. Dưới: scatter plot log-return hàng ngày với đường hồi quy OLS.

Kết quả phân tích tương quan:

- **Tương quan tổng thể:** Pearson $r = 0,528$ — tương quan dương vừa phải, không đủ cao để mô hình một coin có thể thay thế cho coin kia.
- **Tương quan trượt 30 ngày (trung bình):** $r = 0,637$ — trong ngắn hạn, hai coin thường di chuyển cùng chiều do ảnh hưởng của dòng tiền chung vào thị trường.
- **Biến thiên theo thời gian:** Tương quan dao động mạnh (từ dưới 0,2 đến trên 0,8), đặc biệt thấp trong giai đoạn DOGE có pump độc lập (2021). Đây là bằng chứng rõ ràng rằng **nên huấn luyện hai mô hình riêng biệt** thay vì một mô hình chung cho cả hai coin.

3.4. Xây dựng đặc trưng (Feature Engineering)

3.4.1. Thiết kế bộ đặc trưng 9 chiều

Một trong những quyết định quan trọng nhất của đề tài là chọn **9 đặc trưng kỹ thuật** thay vì dùng raw price. Mục tiêu: tập hợp các tín hiệu bổ sung nhau, đều có tính dừng, và không có

redundancy quá mức.


Bảng 3.4: Bộ 9 đặc trưng đầu vào — định nghĩa, giá trị thực tế (BTC) và lý do chọn

#	Tên feature	Mean	Std	Lý do / Vai trò
0	log_return_1d	+0,0014	0,0347	Tín hiệu chuỗi thời gian chính, dùng
1	momentum_30d	+0,0236	0,1163	Xu hướng trung hạn (SMA30 relative)
2	realized_vol_14d	+0,0305	0,0165	Trạng thái biến động hiện tại
3	RSI_14	53,38	13,81	Overbought/oversold momentum
4	log_volume	22,79	2,07	Xác nhận breakout qua khối lượng
5	macd_norm	+0,0047	0,0420	Động lượng ngắn vs. dài hạn
6	bb_pct_b	0,555	0,337	Vị trí trong Bollinger Band
7	atr_norm	+0,0227	0,0263	Proxy ATR — biên độ dao động tức thì
8	fear_greed	0,5	0	Sentiment (placeholder khi không có data)


Giải thích các quyết định quan trọng:

- momentum_30d ($= \text{close}/\text{SMA}_{30} - 1$) thay thế log_return_7d từ v1. Lý do: log-return 7 ngày quá tương quan với log_return_1d (redundancy), trong khi momentum so với SMA30 nắm bắt xu hướng trung hạn độc lập hơn.
- realized_vol_14d (rolling std của log-return 14 ngày) được thêm ở v3 thay cho log_return_30d. Đây là input trực tiếp cho volatility head — mô hình cần “biết” trạng thái biến động gần đây để dự đoán biến động tương lai.
- atr_norm dùng $|\text{log_return_1d}|$ thay vì ATR thực sự (cần high/low giá). Dữ liệu CoinGecko daily chỉ có close/volume, không có OHLC đầy đủ. Đây là **giới hạn của nguồn dữ liệu** cần cải thiện trong tương lai.
- fear_greed hiện tại = 0,5 (neutral) khi không tải được Fear & Greed Index. Feature này là placeholder, chưa mang thông tin thực sự vào mô hình hiện tại.

3.4.2. Phân tích đặc trưng trực quan



Hình 3.7: Chuỗi thời gian của 9 đặc trưng cho Bitcoin (sau khi loại bỏ 29 hàng warmup). RSI_14 thêm đường ngưỡng 30 và 70; bb_pct_b thêm ranh giới dải Bollinger.



Hình 3.8: Ma trận tương quan Pearson giữa 9 đặc trưng (Bitcoin). Giá trị dương = màu đỏ, âm = màu xanh. Tương quan cao nhất giữa `atr_norm` và `realized_vol_14d` ($r \approx 0,7$) là chấp nhận được vì cả hai đo biến động, nhưng ở thang thời gian khác nhau (tức thì vs. 14 ngày).

Hình 3.8 cho thấy phần lớn các feature có tương quan thấp với nhau — đây là tính chất mong muốn. Ngoại lệ duy nhất đáng chú ý là `atr_norm` và `realized_vol_14d` có tương quan cao ($r \approx 0,7$). Hai feature này đều đo volatility nhưng ở thang thời gian khác: `atr_norm` phản ánh biến động tức thì của ngày hôm đó, còn `realized_vol_14d` là trung bình 14 ngày. Sự redundancy vừa phải này được chấp nhận vì volatility head cần cả hai thang thời gian để hoạt động.

3.4.3. Warmup và số hàng hợp lệ

Việc tính SMA30 yêu cầu ít nhất 30 quan sát liên tiếp, đây là constraint lớn nhất trong bộ feature. Sau khi loại bỏ 29 hàng warmup, bộ dữ liệu còn lại $4.165 - 29 = 4.136$ hàng hợp lệ.


3.5. Phân chia tập dữ liệu

3.5.1. Nguyên tắc phân chia chronological

Không giống các bài toán phân loại thông thường, dữ liệu chuỗi thời gian **tuyệt đối không được shuffle** trước khi chia train/val/test. Việc shuffle gây ra **data leakage**: mô hình có thể

“thấy” tương lai trong quá trình huấn luyện, dẫn đến overfitting và kết quả đánh giá sai lệch.

Hệ thống sử dụng **phân chia tuần tự theo thứ tự thời gian** với tỷ lệ **80/10/10**:



Hình 3.9: Phân bố số lượng chuỗi input trong ba tập dữ liệu (cửa sổ training 730 ngày). Tập validation và test mỗi tập tương ứng khoảng 73 ngày liên tiếp cuối cùng của cửa sổ.


3.5.2. Rolling window và cơ chế phân chia

Để tránh mô hình bị áp đảo bởi dữ liệu quá cũ (crypto thay đổi regime nhanh), hệ thống áp dụng tham số `window_days`: chỉ sử dụng **730 ngày gần nhất** (2 năm) làm cửa sổ huấn luyện. Sau đó, cửa sổ này được chia tuần tự:

- **Train:** 80% đầu tiên (khoảng 584 ngày)
- **Validation:** 10% tiếp theo (73 ngày) — dùng để early stopping
- **Test:** 10% cuối (73 ngày) — dùng để báo cáo kết quả cuối cùng

Mỗi chuỗi input **X** có shape (60, 9) — 60 ngày lịch sử $\times$ 9 feature. Mỗi target **y** là vector 7 log-return tương lai tương ứng (MIMO 7-step forecast).

3.5.3. Phân phối nhãn hướng (direction labels)



Hình 3.10: Phân phối target log-return tại bước 1, 3, 7 ngày (Bitcoin). Phương sai tăng dần theo horizon, cho thấy bài toán dự đoán bước 7 khó hơn đáng kể.

Nhãn hướng UP/DOWN được tạo bằng **adaptive-threshold labelling** dựa trên median của training set:

$$y_{\text{dir}}[k] = \begin{cases} 1 \text{ (UP)} & \text{nếu } y[k] > \text{median}(y_{\text{train}}[:, k]) \\ 0 \text{ (DOWN)} & \text{ngược lại} \end{cases}$$

Kết quả là phân phối nhãn **gần như cân bằng hoàn toàn** (Step 1: UP=50,5%, Step 3: UP=51,1%, Step 7: UP=50,7%), tránh được class imbalance problem. Tuy nhiên, đây cũng có nghĩa là ngưỡng UP/DOWN là *tương đối so với median* — không phải tăng/giảm tuyệt đối theo giá gốc. Điều này cần lưu ý khi diễn giải kết quả directional accuracy.

3.6. Tóm tắt chương

- Bộ dữ liệu gồm **4.165 quan sát/coin** trải dài 11,4 năm (2015–2026), chất lượng tốt (dưới 0,03% null).
- Log-return của cả hai coin **dừng mạnh** (ADF $p \approx 0$), xác nhận đây là không gian feature phù hợp. Raw price không dừng (BTC: $p = 0,683$).
- DOGE có **fat tails cực đoan** (kurtosis = 77) và **max drawdown –92%**, đặt ra thách thức lớn hơn cho mô hình dự đoán so với BTC.
- BTC-DOGE có tương quan vừa phải ($r = 0,528$) và biến thiên mạnh theo thời gian → cần hai mô hình riêng biệt.
- Bộ **9 feature** được thiết kế để bổ sung nhau: momentum, volatility, technical indicators, và volume — mỗi loại nắm bắt một khía cạnh khác nhau của động lực giá.
- Feature `fear_greed` hiện là placeholder 0,5 — đây là điểm cần cải thiện trong các phiên bản tiếp theo.

CHƯƠNG 4. PHƯƠNG PHÁP ĐỀ XUẤT

4.1. Tổng quan kiến trúc Lambda

Kiến trúc Lambda của hệ thống chia luồng xử lý thành ba lớp rõ ràng, mỗi lớp phục vụ một mục tiêu khác biệt về độ trễ và độ chính xác:

- **Batch Layer:** Apache Spark Batch xử lý toàn bộ dữ liệu lịch sử từ CSV, tính toán các bộ tập hợp có độ trễ cao nhưng chính xác: `daily_stats` (OHLCV hàng ngày), `historical_sma` (SMA qua nhiều cửa sổ), và `coin_correlation` (tương quan BTC-DOGE theo thời gian).
- **Speed Layer:** Kafka Producer thu thập dữ liệu giá theo thời gian thực từ CoinGecko (mỗi 10 phút), Spark Structured Streaming tiêu thụ topic `crypto_raw`, tính các chỉ số kỹ thuật trên cửa sổ 5 phút và ghi vào MongoDB collection `realtime_prices`.
- **Serving Layer:** MongoDB lưu trữ kết quả từ cả hai lớp trên. FastAPI (port 8000) cung cấp REST API với JWT authentication, phục vụ React frontend (port 3000) và Streamlit dashboard (port 8501). LSTM Inference Scheduler chạy định kỳ mỗi 5 phút, ghi dự đoán 7 ngày vào collection `predictions`.

Luồng dữ liệu hoàn chỉnh được tóm tắt như sau:

CoinGecko API → Kafka (`crypto_raw`) → Spark Streaming → MongoDB
→ FastAPI → React / Streamlit

CSV lịch sử → Spark Batch → MongoDB → FastAPI

CSV lịch sử → LSTM Training → Inference Scheduler → MongoDB
(`predictions`)

4.2. Speed Layer: Kafka và Spark Streaming

4.2.1. Kafka Producer

Producer được cấu hình với các tham số đảm bảo độ tin cậy cao: `acks=all`, `retries=3`, `linger_ms=100`. Mỗi message là JSON chứa giá hiện tại, khối lượng, market cap và timestamp UTC.

4.2.2. Spark Structured Streaming

Spark đọc từ Kafka với Structured Streaming API, xử lý dữ liệu qua cửa sổ trượt 5 phút với watermark 10 phút cho dữ liệu trễ. Kết quả được ghi vào MongoDB thông qua `foreachBatch`

pattern (không dùng streaming sink trực tiếp để đảm bảo idempotency). Các chỉ số kỹ thuật được tính trong Spark:

Bảng 4.1: Các chỉ số kỹ thuật tính toán trong Spark Streaming

Chỉ số	Công thức	Ý nghĩa
SMA- n	$\frac{1}{n} \sum_{i=0}^{n-1} p_{t-i}$	Trung bình động n kỳ
RSI-14	$100 - \frac{100}{1 + \overline{U}_{14}/\overline{D}_{14}}$	Sức mạnh tương đối (overbought >70, oversold <30)
BB	$\text{SMA}_{20} \pm 2\sigma_{20}$	Dải Bollinger — phát hiện breakout
VWAP	$\frac{\sum p_i v_i}{\sum v_i}$	Giá trung bình theo khối lượng
ATR-14	$\frac{1}{14} \sum_{i=1}^{14} \text{TR}_i$	Biên độ dao động thực (True Range)

4.3. Batch Layer: Spark Batch Job

Spark Batch Job xử lý toàn bộ dữ liệu CSV (hàng triệu dòng nếu mở rộng) với DataFrame API, tính và ghi ba collection vào MongoDB:

- `daily_stats`: Tổng hợp OHLCV hàng ngày với các thống kê mô tả.
- `historical_sma`: SMA theo nhiều cửa sổ (7, 30, 90, 200 ngày).
- `coin_correlation`: Rolling Pearson correlation giữa BTC và DOGE theo cửa sổ 30 và 90 ngày.


4.4. Mô hình LSTM Dual-Head (v3)

4.4.1. Kiến trúc tổng thể

Mô hình được xây dựng bằng PyTorch [8] với kiến trúc LSTM 2 lớp (stacked LSTM) và hai đầu ra phụ (auxiliary heads). Thiết kế MIMO (Multiple Input Multiple Output) dự đoán đồng thời tất cả 7 bước thay vì dự đoán tuần tự từng bước, tránh tích lũy sai số.

Bảng 4.2: Thông số kiến trúc mô hình LSTM v3

Thành phần	Chi tiết	Tham số
LSTM Layer 1	input=9, hidden=128, dropout=0,2	70.656
LSTM Layer 2	input=128, hidden=128, dropout=0,2	131.584
Price Head	Linear(128→64)→ReLU→Dropout(0,1)→Linear(64→7)	8.711
Volatility Head	Linear(128→64)→ReLU→Dropout(0,1)→Linear(64→7)→Softplus	8.711
Tổng		219.662

**Hình 4.1:** So sánh số lượng tham số giữa các thành phần của mô hình. LSTM encoder chiếm hơn 90% tổng tham số; các auxiliary heads nhẹ để tránh overfitting.

4.4.2. LSTM Encoder

Công thức cập nhật LSTM tại mỗi timestep t [3]:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{forget gate}) \quad (4.1)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{input gate}) \quad (4.2)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (\text{candidate cell}) \quad (4.3)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (\text{cell state}) \quad (4.4)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (\text{output gate}) \quad (4.5)$$

$$h_t = o_t \odot \tanh(C_t) \quad (\text{hidden state}) \quad (4.6)$$

Hệ thống sử dụng hidden state cuối cùng h_T (với $T = 60$) làm đại diện cho toàn bộ chuỗi lịch sử 60 ngày, sau đó đưa vào các heads.

4.4.3. Price Head và Volatility Head

Price Head dự đoán vector log-return 7 bước: $\hat{\mathbf{y}}_{\text{price}} = W_2 \cdot \text{ReLU}(W_1 h_T + b_1) + b_2$, với shape $(B, 7)$.

Volatility Head dự đoán forward realized volatility 7 bước, đảm bảo giá trị dương bằng hàm Softplus: $\hat{\mathbf{y}}_{\text{vol}} = \text{Softplus}(W_4 \cdot \text{ReLU}(W_3 h_T + b_3) + b_4)$, với shape $(B, 7)$ và $\text{Softplus}(x) = \ln(1 + e^x)$.

4.4.4. Hàm mất mát (Loss Function)

Hàm mất mát kết hợp hai mục tiêu:

$$\mathcal{L} = \alpha \cdot \mathcal{L}_{\text{price}} + \gamma \cdot \mathcal{L}_{\text{vol}} \quad (4.7)$$

với $\alpha = 1,0$, $\gamma = 0,3$ (được chọn qua thực nghiệm).

Direction-weighted Huber Loss cho price head:

$$\mathcal{L}_{\text{price}} = \frac{1}{B \cdot 7} \sum_{b,k} w_{b,k} \cdot \ell_{\delta}(\hat{y}_{b,k} - y_{b,k}) \quad (4.8)$$

trong đó $w_{b,k} = 1 + 2 \cdot \mathbb{I}[\text{sign}(\hat{y}) \neq \text{sign}(y)]$ (phạt gấp 3 lần khi dự đoán sai hướng) và ℓ_{δ} là Huber loss với $\delta = 1$:

$$\ell_{\delta}(r) = \begin{cases} \frac{1}{2}r^2 & \text{nếu } |r| \leq \delta \\ \delta(|r| - \frac{1}{2}\delta) & \text{ngược lại} \end{cases} \quad (4.9)$$

MSE Loss cho volatility head: $\mathcal{L}_{\text{vol}} = \|\hat{\mathbf{y}}_{\text{vol}} - \mathbf{y}_{\text{vol}}\|_2^2$.

4.4.5. Quy trình huấn luyện

Bảng 4.3: Siêu tham số huấn luyện

Siêu tham số	Giá trị
Optimizer	Adam
Learning rate	10^{-3}
Weight decay	10^{-5}
Batch size	64
Max epochs	50
Early stopping patience	7
LR scheduler	ReduceLROnPlateau (factor=0,5, patience=5)
Gradient clipping	max_norm = 1,0

Quá trình huấn luyện sử dụng **early stopping**: dừng sớm nếu validation loss không giảm trong 7 epoch liên tiếp. Mô hình tốt nhất (theo val loss) được lưu lại để dùng cho inference. Gradient clipping với $\text{max_norm} = 1,0$ ngăn chặn exploding gradients — vấn đề phổ biến với LSTM trên dữ liệu tài chính biến động mạnh.

4.5. Walk-Forward Validation

Walk-forward validation [9] là phương pháp đánh giá chuỗi thời gian phù hợp hơn cross-validation thông thường, vì nó mô phỏng quy trình thực tế: chỉ dùng dữ liệu quá khứ để dự đoán tương lai.

Hệ thống sử dụng **6 fold**, mỗi fold gồm 60 ngày validation. Trong mỗi fold: (1) Huấn luyện một mô hình throwaway trên dữ liệu trước fold đó (trong rolling window 730 ngày); (2) Đánh giá trên 60 ngày validation; (3) Tổng hợp RMSE, MAE và directional accuracy. Kết quả cuối là trung bình qua 6 fold.

CHƯƠNG 5. THỰC NGHIỆM VÀ KẾT QUẢ

5.1. Môi trường thực nghiệm

Hệ thống được triển khai bằng Docker Compose với 9 services trên máy cục bộ:

Bảng 5.1: Các services trong Docker Compose

Service	Công nghệ	Port
Zookeeper	Apache Zookeeper 3.7	2181
Kafka Broker	Apache Kafka 3.4	9092
Kafka UI	Provectus Kafka UI	8080
MongoDB	MongoDB 6.0	27017
Spark Master	Apache Spark 3.5	8081
Spark Worker	Apache Spark 3.5	—
Producer	Python (pycoingecko)	—
Dashboard	Streamlit 1.32	8501
API Backend	FastAPI + Uvicorn	8000
Frontend	React 19 + Nginx	3000
Inference Scheduler	PyTorch 2.2	—

Cấu hình phần cứng thực nghiệm: CPU Intel Core i7 (8 cores), RAM 16 GB, lưu trữ SSD. Mô hình LSTM huấn luyện trên CPU (không cần GPU do dataset nhỏ 3.000 mẫu).

5.2. Quy trình thực nghiệm

1. Khởi động infrastructure: `make docker-up`
2. Tạo Kafka topics: `bash scripts/create_topics.sh`
3. Điền dữ liệu lịch sử vào MongoDB: `bash scripts/run_batch.sh`
4. Huấn luyện LSTM và chạy inference: `make infer-all`
5. Đánh giá backtest 6 tháng: `python src/ml/backtest_compare.py`
6. Xem kết quả qua React frontend (port 3000)

5.3. Độ đo đánh giá

- **RMSE** (Root Mean Squared Error): $\sqrt{\frac{1}{M \cdot 7} \sum_{m,k} (\hat{p}_{m,k} - p_{m,k})^2}$ tính trên giá USD tái tạo.
- **MAE** (Mean Absolute Error): $\frac{1}{M \cdot 7} \sum_{m,k} |\hat{p}_{m,k} - p_{m,k}|$ tính trên giá USD tái tạo.

- **Directional Accuracy:** $\frac{1}{M} \sum_m \mathbb{I}[\text{sign}(\hat{r}_{m,1}) = \text{sign}(r_{m,1})]$ — đúng hướng bước 1.
- **Walk-Forward Dir Acc:** Trung bình directional accuracy qua 6 fold walk-forward.


Lưu ý: RMSE và MAE được tính trên giá USD tái tạo từ cumulative log-return, không phải trực tiếp trên log-return chuẩn hóa.

5.4. Kết quả trên tập kiểm thử

5.4.1. So sánh BTC và DOGE

Bảng 5.2: Kết quả trên tập test (10% cuối của rolling window 730 ngày, 73 ngày)


Coin	RMSE	MAE	Dir Acc (bước 1)	Epochs trained
Bitcoin (BTC)	\$1.799,50	\$1.288,92	40,0%	10
Dogecoin (DOGE)	\$0,00325	\$0,00267	20,0%	18



Hình 5.1: So sánh hiệu suất mô hình BTC và DOGE theo các độ đo. BTC có RMSE tuyệt đối lớn hơn nhiều (theo USD) nhưng MAPE thấp hơn DOGE do giá BTC cao hơn.

Phân tích: Directional accuracy thấp (40% cho BTC, 20% cho DOGE) trên tập test thuần túy phản ánh đặc thù của bài toán: mô hình được huấn luyện để tối thiểu hóa Huber loss trên log-return, không trực tiếp tối đa hóa directional accuracy. Hơn nữa, tập test chỉ có ~ 73 quan sát — đủ nhỏ để kết quả có thể dao động lớn theo thời kỳ thị trường. Kết quả walk-forward (nhiều fold, dữ liệu đa dạng hơn) đáng tin cậy hơn để đánh giá tổng quát.


5.4.2. Phân tích MAE theo từng bước dự đoán




Hình 5.2: MAE theo từng bước dự đoán (step 1–7) cho BTC và DOGE. MAE tăng dần theo horizon — step 7 khó hơn step 1 đáng kể, đặc biệt với DOGE do biến động cao.

Hình 5.2 cho thấy xu hướng tự nhiên: **sai số tích lũy theo horizon**. Ở step 1 (ngày tiếp theo), mô hình BTC đạt MAE thấp nhất; đến step 7 (7 ngày sau), bất định của thị trường làm sai số tăng đáng kể. Xu hướng này xác nhận rằng mô hình LSTM hoạt động tốt hơn cho dự đoán ngắn hạn (1–3 ngày) so với dài hạn (7 ngày).

5.4.3. Dự đoán vs. Giá thực tế




Hình 5.3: Scatter plot giá dự đoán vs. giá thực tế (USD) trên tập test, tất cả 7 bước. Đường nét đứt là đường lý tưởng $\hat{p} = p$. Điểm gần đường này hơn = dự đoán chính xác hơn.



Hình 5.4: Phân tích phần dư (residuals) của mô hình BTC: phân phối residuals (trái) và residuals theo thứ tự thời gian (phải). Không có autocorrelation rõ ràng — tốt cho mô hình hồi quy.


5.4.4. Trực quan hóa dự đoán 7 ngày



Hình 5.5: Ví dụ dự đoán 7 ngày cho BTC (đường xanh dương) so với giá thực tế (đường cam). Vùng tô màu biểu diễn khoảng tin cậy ± 1 vol từ volatility head.

Hình 5.5 minh họa một trong những điểm mạnh của mô hình v3: khoảng tin cậy dự đoán từ **volatility head**. Thay vì chỉ đưa ra dự đoán điểm, mô hình cung cấp thêm ước lượng về mức độ bất định của dự đoán. Trong các giai đoạn biến động cao, vùng tô màu rộng hơn — tín hiệu hữu ích cho nhà đầu tư về rủi ro.

5.4.5. Phân tích Volatility Head



Hình 5.6: So sánh volatility được dự đoán bởi volatility head (nét xanh) với realized volatility thực tế (nét cam). Mô hình học được pattern “volatility clustering” — giai đoạn biến động cao nối tiếp nhau.


Volatility head của mô hình v3 thành công trong việc học được **volatility clustering** — hiện tượng phổ biến trong tài chính nơi các giai đoạn biến động cao có xu hướng nối tiếp nhau. Điều này thể hiện qua Vol head RMSE của BTC là 0,794 (đơn vị chuẩn hóa) và DOGE là 0,622, đây là kết quả có ý nghĩa thực tiễn dù chưa hoàn hảo.

5.5. Walk-Forward Validation

5.5.1. Kết quả tổng hợp

Bảng 5.3: Kết quả walk-forward validation (6 fold $\times$ 60 ngày/fold)

Coin	WF RMSE (mean)	WF MAE (mean)	WF Dir Acc (mean)
Bitcoin (BTC)	\$3.604,46	\$2.482,59	49,38%
Dogecoin (DOGE)	\$0,01357	\$0,01000	46,30%



Hình 5.7: Directional accuracy theo từng fold walk-forward cho BTC và DOGE. Dao động giữa các fold (38%–56%) phản ánh sự thay đổi regime của thị trường crypto qua các giai đoạn khác nhau.

5.5.2. Kết quả theo từng fold (Bitcoin)

Bảng 5.4: Chi tiết từng fold walk-forward — Bitcoin (horizon = 7 ngày)

Fold	RMSE (\$)	MAE (\$)	Dir Acc (%)	Train seqs	Val seqs
1	3.902,36	2.839,79	46,30	635	54
2	3.028,61	2.414,67	50,00	635	54
3	4.810,39	3.772,89	50,00	635	54
4	3.160,48	2.378,17	55,56	635	54
5	4.144,19	2.971,94	38,89	635	54
6	2.580,73	2.094,28	55,56	635	54
Trung bình	3.604,46	2.578,62	49,38	—	—

Biến động lớn giữa các fold (RMSE từ \$2.580 đến \$4.810) là đặc tính bình thường của thị trường crypto: mô hình hoạt động tốt trong các giai đoạn trending (fold 2, 4, 6) và kém hơn trong giai đoạn sideways hoặc crash đột ngột (fold 3, 5).

5.6. Backtest 6 Tháng (Bitcoin)

5.6.1. Phương pháp

Backtest được thực hiện trên dữ liệu Bitcoin từ **23/01/2026 đến 29/05/2026** (6 tháng gần nhất), mô phỏng quy trình thực tế: mô hình không “thấy” dữ liệu trong giai đoạn này trước khi đánh giá. Mỗi cửa sổ n ngày được đánh giá độc lập.

5.6.2. Kết quả so sánh đa horizon

Bảng 5.5: Kết quả backtest BTC theo horizon (6 tháng: 01/2026–05/2026)

Horizon	Số cửa sổ	RMSE (mean)	MAE (mean)	Dir Acc	Mean Err %
7 ngày	18	\$3.009,77	\$2.593,60	61,1%	0,37%
15 ngày	8	\$4.289,60	\$3.510,45	50,0%	2,72%
60 ngày	2	\$13.452,73	\$12.385,02	50,0%	15,89%

Nhận xét quan trọng:

- **Horizon 7 ngày** cho kết quả tốt nhất với Dir Acc = **61,1%** trên 18 cửa sổ — vượt ngưỡng random (50%) có ý nghĩa thực tiễn. Mean Error = 0,37% cho thấy mô hình không có bias hệ thống theo một chiều.
- **Horizon 15 và 60 ngày** đều giảm về Dir Acc = 50% (ngẫu nhiên), phản ánh giới hạn của LSTM cho dự đoán dài hạn. RMSE tăng theo cấp số nhân theo horizon là kết quả dự kiến vì bất định tích lũy.
- **Sự kiện đặc biệt:** Cửa sổ 30/01–05/02/2026 có RMSE = \$11.086 do crash bất ngờ từ \$84.561 xuống \$62.702 (–25,8% trong 7 ngày). Đây là loại sự kiện cực đoan (tail event) mà bất kỳ mô hình nào cũng khó dự đoán.

CHƯƠNG 6. KẾT LUẬN

6.1. Tóm tắt đóng góp

Đề tài đã thiết kế và xây dựng thành công một hệ thống phân tích và dự đoán giá tiền mã hóa end-to-end, đóng góp ở bốn khía cạnh chính:

1. Pipeline Lambda Architecture hoàn chỉnh. Hệ thống tích hợp đầy đủ ba lớp của kiến trúc Lambda: batch layer (Spark Batch), speed layer (Kafka + Spark Streaming), và serving layer (MongoDB + FastAPI). Toàn bộ được container hóa với Docker Compose (9 services), có thể khởi động với một lệnh duy nhất (`make docker-up`).

2. Mô hình LSTM v3 với volatility head. Đề tài đề xuất kiến trúc LSTM với hai đầu ra phụ: price head (dự đoán log-return 7 bước) và volatility head (dự đoán realized volatility 7 bước). Volatility head cung cấp khoảng tin cậy cho dự đoán giá — tính năng thực tiễn không có trong các mô hình LSTM đơn giản. Mô hình sử dụng direction-weighted Huber loss để ưu tiên dự đoán đúng hướng.

3. Đánh giá nghiêm túc với walk-forward và backtest. Thay vì chỉ báo cáo kết quả trên tập test tĩnh, đề tài thực hiện walk-forward validation (6 fold) và backtest 6 tháng. Kết quả cho thấy mô hình đạt directional accuracy 61,1% cho horizon 7 ngày trong backtest thực tế — có ý nghĩa thực tiễn khi so với ngưỡng random 50%.

4. Hệ thống frontend hoàn chỉnh. React 19 frontend với 5 trang phân tích (Dashboard, Realtime, Technical, Predictions, Correlation), JWT authentication, và model registry quản lý nhiều phiên bản mô hình.

6.2. Hạn chế và điểm cần cải thiện

- Feature `fear_greed` là placeholder:** Hiện tại luôn = 0,5 (neutral), không mang thông tin thực sự. Cần tích hợp API Fear & Greed Index thực.
- Thiếu OHLC đầy đủ:** Dữ liệu CoinGecko daily chỉ có close/volume. ATR thực sự cần high/low giá; hiện tại dùng `|log_return|` làm proxy.
- Directional accuracy thấp trên tập test tĩnh:** BTC đạt 40%, DOGE đạt 20% trên tập test ngắn (73 ngày). Kết quả này nhạy cảm với thời kỳ thị trường cụ thể và không phản ánh đầy đủ hiệu suất tổng thể.
- Mô hình chưa xét yếu tố ngoại sinh:** Sự kiện bên ngoài (tweet, quy định pháp lý, fork) tác động mạnh đến giá crypto nhưng không được mã hóa trong features.
- Horizon dài hạn (≥ 15 ngày) không hiệu quả:** Directional accuracy chỉ đạt 50% (random) cho horizon 15 và 60 ngày, cho thấy LSTM đơn giản không phù hợp cho dự đoán dài hạn.

6.3. Kết luận

Đề tài đã trả lời được câu hỏi nghiên cứu chính: *Có thể xây dựng một hệ thống phân tích crypto theo thời gian thực kết hợp Lambda Architecture và học sâu LSTM hay không?* Câu trả lời là có, với các kết quả cụ thể và đánh giá nghiêm túc.

Kết quả backtest 6 tháng với directional accuracy 61,1% cho horizon 7 ngày là tín hiệu tích cực, vượt ngưỡng random 11,1 điểm phần trăm. Tuy nhiên, kết quả này cần được diễn giải thận trọng: đây chỉ là 18 cửa sổ trên một giai đoạn thị trường cụ thể. Dự đoán giá crypto trong dài hạn vẫn là bài toán mở do bản chất phi tuyến và nhạy cảm với yếu tố bên ngoài của thị trường.

CHƯƠNG 7. HƯỚNG PHÁT TRIỂN

- **Tích hợp sentiment thực:** Thay placeholder `fear_greed` bằng API thực (Alternative.me Fear & Greed Index). Thêm dữ liệu sentiment từ Twitter/Reddit qua NLP (BERT, FinBERT).
- **Kiến trúc mô hình nâng cao:** Thử nghiệm Temporal Fusion Transformer (TFT) [2] và Informer cho dự đoán chuỗi thời gian dài. TFT có cơ chế attention giải thích được, phù hợp cho bài toán tài chính.
- **OHLC đầy đủ:** Chuyển sang nguồn dữ liệu cung cấp giá high/low/open (ví dụ: Binance API), cho phép tính ATR thực và các chỉ số candlestick pattern.
- **Kappa Architecture:** Đơn giản hóa kiến trúc bằng cách thay batch layer bằng stream reprocessing (Kafka Streams hoặc Flink), giảm độ phức tạp vận hành.
- **Backtesting chiến lược giao dịch:** Tích hợp module mô phỏng giao dịch (Backtrader, Zipline) để chuyển từ directional accuracy sang Sharpe ratio và PnL thực tế.
- **Triển khai cloud:** Migrate lên AWS/GCP với Kubernetes và managed Kafka (MSK, Confluent Cloud), Spark (EMR, Dataproc), đảm bảo scalability cho nhiều coin hơn.
- **Mở rộng đa coin:** Thêm Ethereum (ETH), Binance Coin (BNB), Solana (SOL), phân tích tương quan đa chiều và cross-coin feature engineering.

Tài liệu tham khảo

- [1] Thomas Fischer and Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018. doi: 10.1016/j.ejor.2017.11.054.
- [2] Bryan Lim, Sercan Ö. Arık, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748–1764, 2021. doi: 10.1016/j.ijforecast.2021.03.012.
- [3] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. doi: 10.1162/neco.1997.9.8.1735.
- [4] Matei Zaharia, Reynold S. Xin, Patrick Wendell, Tathagata Das, Michael Armbrust, Ankur Dave, Xiangrui Meng, Josh Rosen, Shivaram Venkataraman, Michael J. Franklin, Ali Ghodsi, Joseph Gonzalez, Scott Shenker, and Ion Stoica. Apache spark: A unified engine for big data processing. *Communications of the ACM*, 59(11):56–65, 2016. doi: 10.1145/2934664.
- [5] Nathan Marz and James Warren. *Big Data: Principles and Best Practices of Scalable Realtime Data Systems*. Manning Publications, Shelter Island, NY, 2015.
- [6] John J. Murphy. *Technical Analysis of the Financial Markets*. New York Institute of Finance, New York, NY, 2nd edition, 1999.
- [7] CoinGecko. CoinGecko API – Cryptocurrency Market Data. <https://www.coingecko.com/api/documentation>, 2024. Accessed: June 2026.
- [8] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems 32*, pages 8024–8035. Curran Associates, Inc., 2019.
- [9] Vitor Cerqueira, Luís Torgo, and Igor Mozetič. Evaluating time series forecasting models: An empirical study on performance estimation methods. *Machine Learning*, 109(11): 1997–2028, 2020. doi: 10.1007/s10994-020-05910-7.